S08

Datos de presencia de GBIF

PROGRAMACIÓN EN R | SIG Y CARTOGRAFÍA

GBIF (Global Biodiversity Information Facility) reúne cientos de millones de registros de especies de museos, proyectos de ciencia ciudadana y censos. Son muy valiosos, pero llegan con errores y sesgos. Hoy aprendes a descargarlos, limpiarlos con criterios explícitos y detectar el sesgo de muestreo.

DURACIÓN	Unas 2 horas.
PAQUETES	`rgbif`, `CoordinateCleaner`, `sf`, `tidyverse`
ARCHIVOS	`semana08_datos_GBIF.R`, `semana08_soluciones.R`, `gbif_lullula_arborea_raw.csv`, `montfred.gpkg`
DATOS	286 registros de alondra totovía (Lullula arborea) que imitan una descarga de GBIF, con errores típicos añadidos a propósito.

Objetivos

- buscar y descargar registros con `rgbif`, y saber cuándo usar `occ_download()`;
- reconocer los errores más comunes en registros de presencia;
- limpiar los datos paso a paso y con `CoordinateCleaner`, documentando cada paso;
- detectar el sesgo de muestreo y reducirlo con un aclarado espacial.

1 · Descargar de GBIF

```
library(rgbif)
key <- name_backbone("Lullula arborea")$usageKey      # identificador taxonómico
occ_search(taxonKey = key, country = "ES", hasCoordinate = TRUE,
           year = "2015,2025", limit = 500)$data        # para explorar
# Para publicar: occ_download() con tu cuenta de GBIF; genera un DOI que hay que citar
```

En clase usamos un archivo preparado para que todos tengamos los mismos datos y los mismos errores. En el script, la descarga real está dentro de `if (run_gbif)`: cambia `run_gbif` a TRUE para probarla.

2 · Errores típicos

Problema	Cómo se detecta
Coordenadas (0, 0)	prueba "zeros" de CoordinateCleaner
Latitud y longitud intercambiadas	el punto cae en otro continente; filtro espacial
Capital o centroide del país (georreferenciación por defecto)	pruebas "capitals" y "centroids"
Incertidumbre de varios km	`coordinateUncertaintyInMeters`
Fósiles y especímenes de museo antiguos	`basisOfRecord, year`
Duplicados (el mismo registro en dos plataformas)	`distinct()`

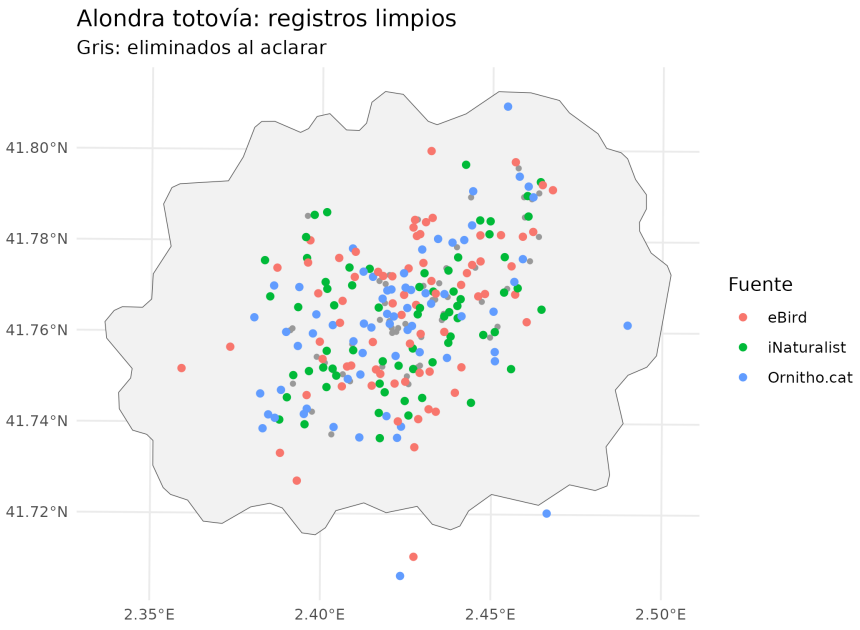
3 · Limpiar documentando

El script guarda cuántos registros quedan tras cada paso con una pequeña función, `log_step()`. Esa tabla va directa a la sección de métodos:

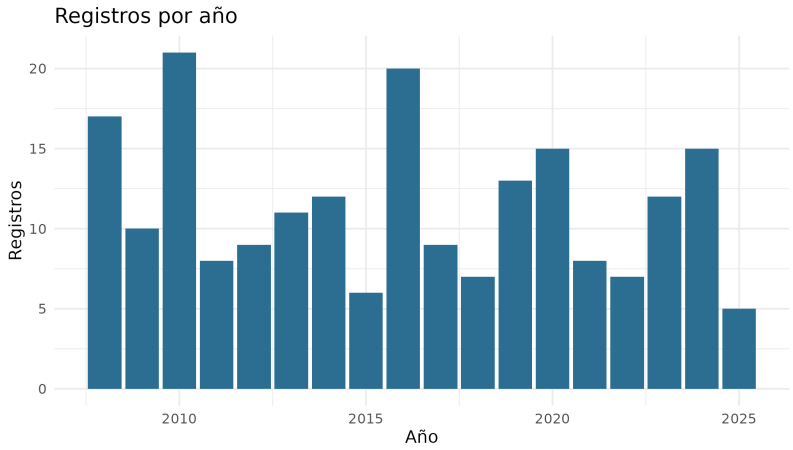
Paso	Quedan
0 Descarga original	286
1 Solo observaciones (sin fósiles ni especímenes)	284
2 Año 2000 o posterior	282
3 Incertidumbre de 1.000 m o menos	279
4 Sin duplicados	267
5 CoordinateCleaner	263
6 Dentro de la zona de estudio	260
7 Aclarado a una celda de 250 m	205

4 · Sesgo de muestreo y aclarado

Los registros se acumulan donde va la gente: caminos, miradores, refugios. Si un modelo aprende de esos grupos, aprende "dónde hay observadores". Quedarse con un registro por celda de 250 m reduce ese efecto. Fíjate también en qué fuentes aportan más datos y en qué años.



Registros limpios por fuente. En gris, los eliminados al aclarar.



Registros por año tras la limpieza.

Cita los datos

Las descargas con occ_download() tienen un DOI. Cítalo en cualquier trabajo que use esos datos: es la condición de uso de GBIF y reconoce a quien los recogió.

Ejercicios

Soluciones en `semana08_soluciones.R`.

1. Tabla con cuántos registros quitó cada paso de limpieza.
2. ¿Qué pruebas de CoordinateCleaner marcaron registros?
3. Repite el aclarado con celdas de 500 m. ¿Cuántos registros quedan?
4. ¿Qué fuente aporta más registros? ¿Puede sesgar un modelo?
5. Con internet: descarga registros de alondra totovía de tu provincia con rgbif.

Antes de la semana 9

- Instala `install.packages(c("spdep", "gstat", "spatstat"))`.
- Guarda `gbif_lullula_arborea_clean.csv`: lo usamos en la semana 10.